

Duplicidades- Campanha Corrigida

1. QUANTAS DUPLICIDADES FOI ENCONTRADA?

- 101.244 linhas no total;
- 84.535 linhas completamente idênticas a outras linhas;
- 16.709 timestamps diferentes.
- O padrão encontrado foi de 6 registros para o mesmo timestamp

Quantidade de registros por timestamp	Quantidade de timestamps
1	2
3	8
4	2
5	10
6	15.674
7	1.011
18	1
21	1

2. ONDE ENCONTROU?

Verificação 1 — Mesmo timestamp

Primeiro, juntamos:

data + hora

para formar o timestamp completo.

Depois foi contado quantas vezes cada timestamp aparece.

Exemplo: 16:03:57 → 6 registros

Portanto, existem:

5 registros excedentes nesse timestamp.

Aplicando essa regra a toda a base:

101.244 registros originais - 16.709 timestamps únicos = 84.535 registros excedentes.

Verificação 2 — Linha completamente igual

Também verificamos se a **linha inteira** é repetida, considerando:

- data;
- hora;
- corrente A;
- potência VA.

Nesse caso encontramos:

80.965 linhas excedentes de duplicações exatas.

Isso significa que essas linhas possuem os mesmos valores em todas essas colunas.

Por que 80.965 e 84.535 são diferentes?

Porque:

84.535 considera qualquer registro adicional dentro do mesmo timestamp.

Já:

80.965 considera somente registros que são **completamente iguais em todas as colunas**

3. QUAL REGRA FOI UTILIZADA?

Manter um único registro para cada timestamp (data + hora), considerando o primeiro registro encontrado para aquele timestamp, e tratar os demais registros do mesmo timestamp como registros repetidos para fins de consolidação.

Assim:

Base original

101.244 registros

↓

Agrupamento por timestamp

16.709 timestamps distintos



Base consolidada

16.709 registros

4. O QUE FOI FEITO COM OS REGISTROS REPETIDOS?

Não foram apagados da base bruta; foram excluídos da base consolidada

OBS:

Duplicidades: Foram identificados registros repetidos ao longo de praticamente toda a base. A identificação foi realizada agrupando os registros pelo timestamp, composto pela data e hora, e também pela comparação dos valores de todas as colunas. A base possui 101.244 registros e 16.709 timestamps distintos. Considerando a regra de manter um único registro por timestamp, foram identificados 84.535 registros excedentes. Na verificação de duplicidade exata de todas as colunas, foram identificados 80.965 registros excedentes. Para a consolidação, foi mantido o primeiro registro de cada timestamp, resultando em uma base consolidada com 16.709 registros. Os registros repetidos não foram excluídos da base bruta, sendo apenas desconsiderados na base consolidada.